Verslag AD 3: Lukas Barragan Torres

Inleiding

Dit verslag is gemaakt voor het vak Algoritmen en Datastructuren 3 aan de Universiteit Gent. De bedoeling van dit project is om een programma te ontwikkelen dat een bestand kan comprimeren, dit gecomprimeerd bestand (extern) kan sorteren om het daarna te extraheren. Dit verslag behandelt verschillende ontwerpbeslissingen en benchmarks, om af te sluiten met implementatie opmerkingen en een conclusie.

Ontwerpbeslissingen en implementatie

Tree

Er zijn meerdere mogelijkheden om een orde-bewarende prefixboom op te stellen. In deze sectie wordt uitgelegd waarom een standaard Huffman implementatie niet zomaar volstaat en geeft vervolgens twee algoritmes die dit wel correct doen, namelijk het algoritme van Hu-Tucker en het algoritme van Knuth. Beide zijn geïmplementeerd in het project, maar enkel Hu-Tucker wordt gebruikt.

Huffman

Wanneer we van een frequentietabel naar een orde bewarende prefixboom willen gaan kunnen we niet zomaar het standaard Huffman algoritme gebruiken. Dit is makkelijk te zien met een voorbeeld. Stel dat de volgende tekst gecomprimeerd moet worden:

```
ABBC
```

Dan zal volgens het Huffman algoritme de karakters met de laagste frequentie eerst samengenomen worden, namelijk `A` en `C` . Daarna wordt deze net aangemaakte deelboom samengenomen met het karakter `B`. De prefixboom die hieruit ontstaat kan onmogelijk orde-bewarend zijn. Moest dit wel zo zijn zou `Code(A) < Code(B) < Code(C)` , maar aangezien `A` en `C` zusterknopen zijn, verschillen hun codes met exact 1. Hier kan `Code(B)` dus onmogelijk tussen.

Men moet wel opletten, want er zijn gevallen waar de Huffman-code orde-bewarend is. Neem de volgende tekst:

```
ABCC
```

Hier zal het Huffman algoritme wel een orde-bewarende code genereren (mits het kleinste karakter in de linkertak geplaatst wordt bij het samennemen). Dit voorbeeld zal volgende

codes genereren:

```
A: 00
B: 01
C: 1
```

Hu-Tucker

Het Hu-Tucker algoritme[1] werkt als volgt. Men begint met de frequenties - gesorteerd volgens karakter - op een rij. Al deze frequenties worden initieel gelabeld als `TERMINAL` (dit komt omdat al deze knopen bladeren voorstellen). Daarna neem je het paar met de kleinste som van frequenties, zonder dat er een `TERMINAL` knoop tussen deze knopen zit. Je vervangt de linkerknoop uit het paar met de nieuwe samengevoegde knoop (identiek aan het Huffman algoritme, hier wordt dus een klein boompje van gemaakt met opgetelde frequentie) en verwijderd de rechter knoop uit de lijst. Daarna label je deze nieuwe knoop met `INTERNAL`. Doe dit tot er maar één knoop meer overblijft. deze knoop stelt een boom voor. Deze boom is niet noodzakelijk een orde-bewarende boom. Bereken van elk blad in de boom de lengtes. Begin daarna bij de lengte l_0 van het meest linkse blad. de eerste code bestaat dan uit l_0 nullen. volgende codes worden op volgende manier gevonden:

1. Tel 1 op bij de vorige code[2]
2. Vul de code aan met nullen of neem er weg tot deze even lang is als de lengte

Illustratie ter voorbeeld. De lengtes `3, 3, 2, 4, 4, 4, 4` geven de codes `000, 001, 01, 1000, 1001, 1010, 1011, 11`

Het opstellen van de initiële boom waaruit de lengtes worden gehaald kan technisch gezien in $\theta(n * log(n))$ met n het aantal karakters. Aangezien wij over maximaal 128 karakters lopen koos ik voor een simpele $\theta(n^2)$ implementatie, waarbij heel de lijst overlopen wordt tijdens het zoeken naar het kleinste paar. De lengtes van van de bladeren vinden en hieruit de codes berekenen is $\theta(n)$. Het algoritme is dus $\theta(n^2)$.

Knuth

Naast het Hu-Tucker algoritme implementeer heb ik ook nog het algoritme van Knuth[3] voor het opstellen van een optimale orde-bewarende boom geïmplementeerd. Deze heb ik uiteindelijk niet gebruikt maar is wel nog te vinden in de code (`make_OPC.c`).

Het algoritme voor het bouwen van een optimale alfabetische binaire boom berust op het principe dat in een optimale OPC boom, zowel de linker- als de rechter kinderboom ook optimaal zijn. Dit principe wordt toegepast in een dynamisch programmeringskader met de matrix `M`. In `M` staat elke cel `M[i][j]` in de rechter bovenhelft voor de kosten van de optimale boom met karakters van `i` tot `j`, berekend door alle mogelijke splitsingen van de karakterreeks te overwegen en de kosten van de optimale linker- en rechter sub-bomen op

te tellen. De linker onderhelft van `M` bevat de som van de frequenties van de karakters in elke sub-reeks. Door dit principe te volgen, bouwt het algoritme voort op de berekende kosten van kleinere, optimale sub-bomen om stapsgewijs de kosten van grotere bomen te vinden, wat leidt tot de optimale boomstructuur voor de gehele reeks karakters. Het algoritme van Knuth is $\theta(n^3)$

Comprimeren

Voor het comprimeren van bestanden heb ik een aantal belangrijke keuzes gemaakt.

- Gecodeerde lijnen zijn **niet** gealigneerd tot de volgende byte, uint64, etc.
- De lengte van elke lijn wordt ook ongealigneerd bijgehouden in het bestand.
- Lijnlengtes bevinden zich in de header (technisch gezien footer)
- `\n` wordt **wel** gecodeerd.
- Er is een byte die aangeeft of het bestand reeds gesorteerd werd.

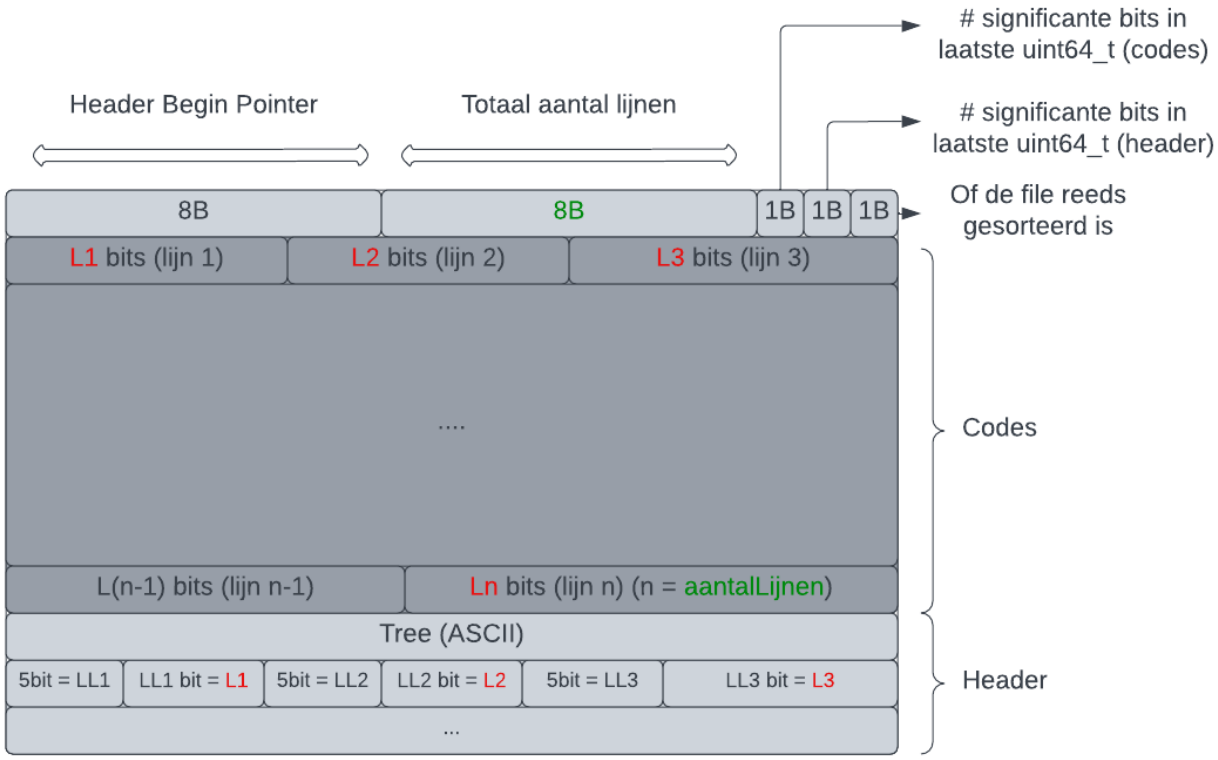

Gecodeerde lijnen

Een gecodeerde lijn is vrij simpel. De karakters worden gecodeerd en vervolgens uitgeschreven als bit-sequentie. Dit wil zeggen dat deze kan beginnen en eindigen middenin een byte.

Lijnlengtes

Het project specifieerd dat het programma een gecomprimeerd bestand kan sorteren aan de hand van orde-bewarende prefix codes. Je zou tijdens het sorteren karakters één per één

kunnen extraheren om zo de newlines te kunnen identificeren, maar dit gaat helemaal in tegen het principe van de orde-bewarende prefix code. Daarom bevat de header de lengte van elke lijn. Dit heeft verschillende voordelen die uitgediept worden in de sorteren-sectie van het verslag.

Het is wel duidelijk dat deze lijnlengtes met een hevige overhead gepaard gaan. Bij een naïeve implementatie zou voor elke lijnlengte 22 bits nodig zijn. Dit komt omdat de maximale lijnlengte `45354` is en de lengte van een code maximaal `64` is. Om de lengte van deze gecodeerde lijn voor te stellen heb je dus $ceil(log_2(45354 \cdot 64)) = 22$ bits nodig. Echter, wanneer we naar de distributie kijken van gecodeerde lijnlengtes voor bijvoorbeeld `tiny.txt`,

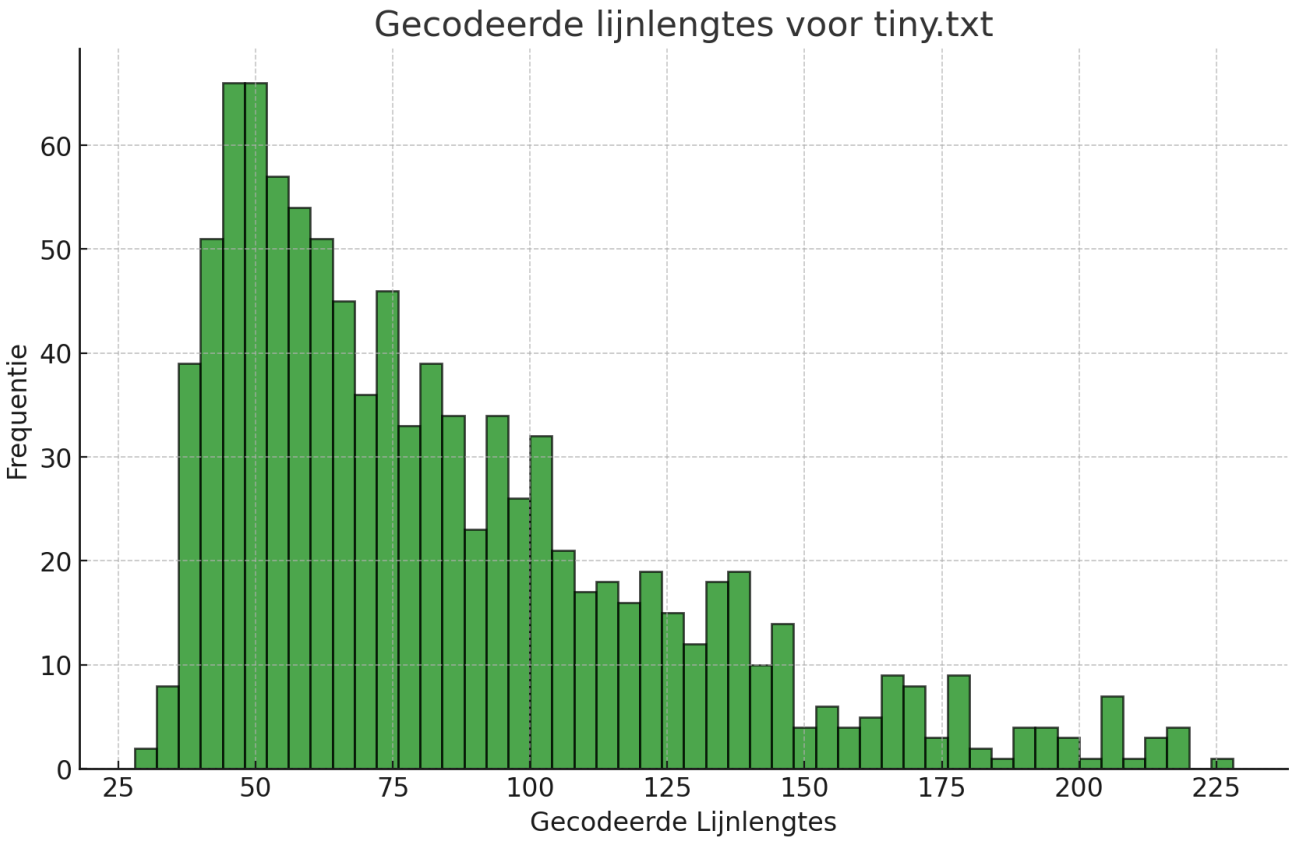

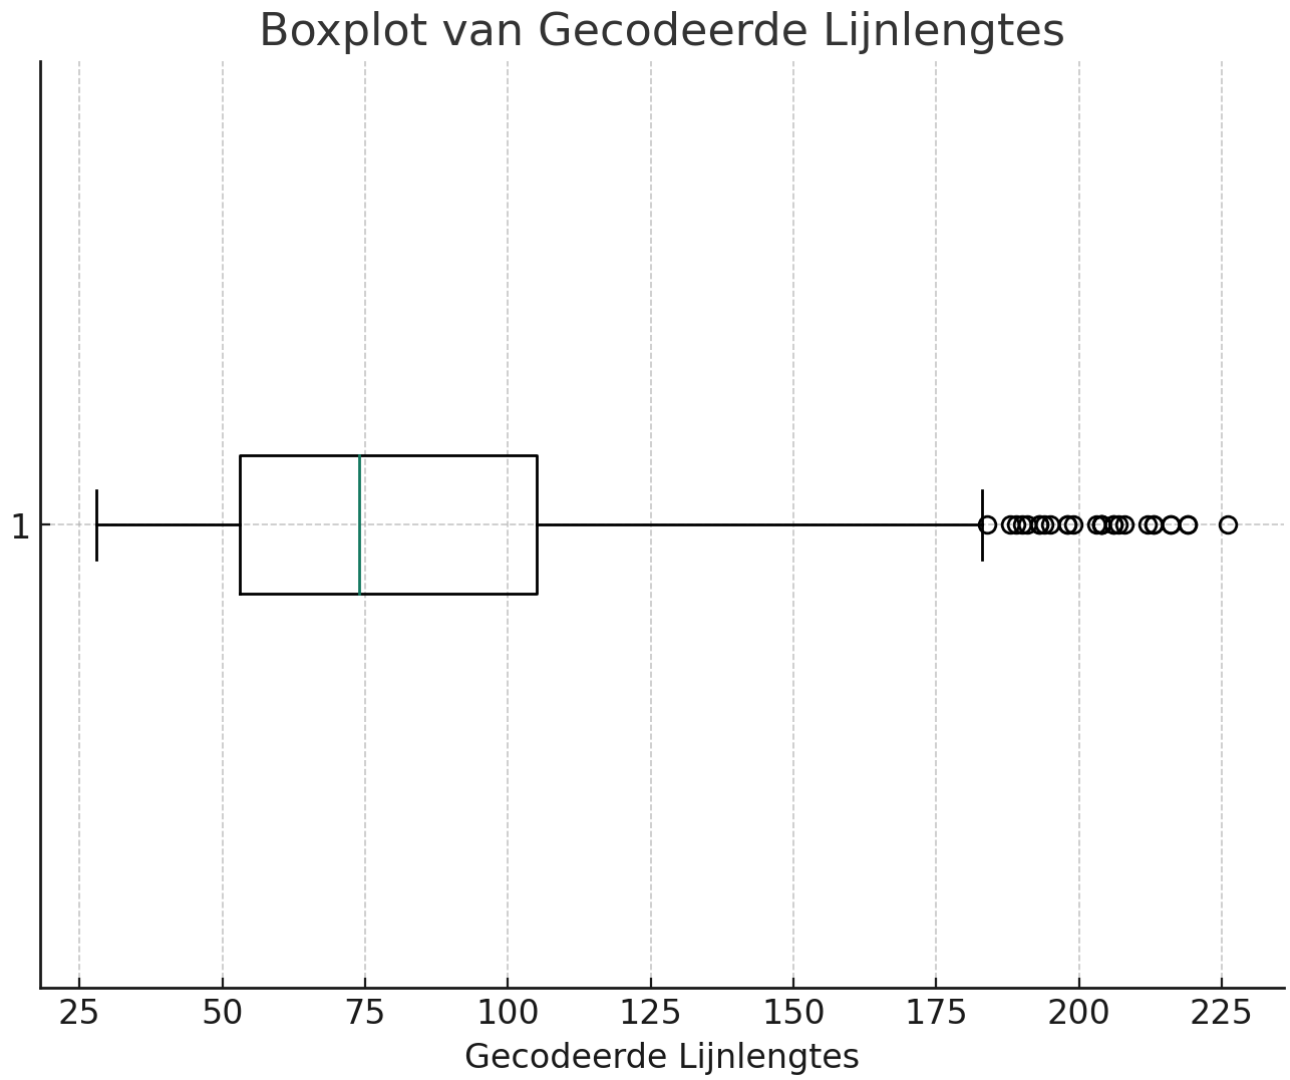

dan zien we dat de meeste lijnen helemaal niet zo lang zijn. Een oplossing hiervoor is om een lijnlengte op te splitsen in twee delen. Het eerste deel bestaat uit $ceil(log_2(22)) = 5$ bits die de lengte van de lengte van de lijn aangeeft (op het compressie-diagram aangegeven met `LL`). Het tweede deel is dan `LL` bits die de werkelijke lengte bevatten. Met deze aanpassing gebruiken we op `tiny.txt` ongeveer 47% minder bits voor het opslaan van de lijnlengtes.

Header (footer)

De header met alle lijnlengtes bevindt zich op het einde van het bestand. Deze ontwerpbeslissing heb ik genomen voor een aantal redenen:

- Lijnlengtes kunnen snel sequentieel overlopen worden zonder te springen in het bestand.
- Tijdens het comprimeren is geen tussentijdse buffer nodig om de lijn in op te slaan zodat de lengte kan uitgeschreven worden naar het bestand vóór de lijn.
- Deze header kan gemakkelijk weggelaten worden na het sorteren.

Dit laatste is ook de reden dat er in het begin van het bestand een byte is dat aangeeft of het bestand ooit al gesorteerd werd. De lijnlengtes werden tijdens compressie bijgehouden om

efficiënt en zonder te extraheren te kunnen sorteren, maar wanneer een bestand al gesorteerd is geweest zullen deze waarden nooit meer gebruikt worden[4]. Neem als voorbeeld `large.txt`. Deze is `945 MiB`. Na het comprimeren wordt dit `592 MiB`. Wanneer uiteindelijk gesorteerd wordt zal de grootte nog dalen naar `523 MiB`.

Deze keuze verklaart ook waarom newlines gecodeerd worden. Moest dit niet gebeuren zou extraheren zonder lijnlengtes niet meer mogelijk zijn omdat niet duidelijk is waar een lijn eindigt.

Compressie factor

De compressiefactor is afhankelijk van het aantal unieke karakters, de frequentieverdeling en de lengte van de lijnen (veel korte lijnen gaan meer lijnlengtes in de header genereren). Voor de meegegeven test-bestanden zijn de compressiefactoren als volgt:

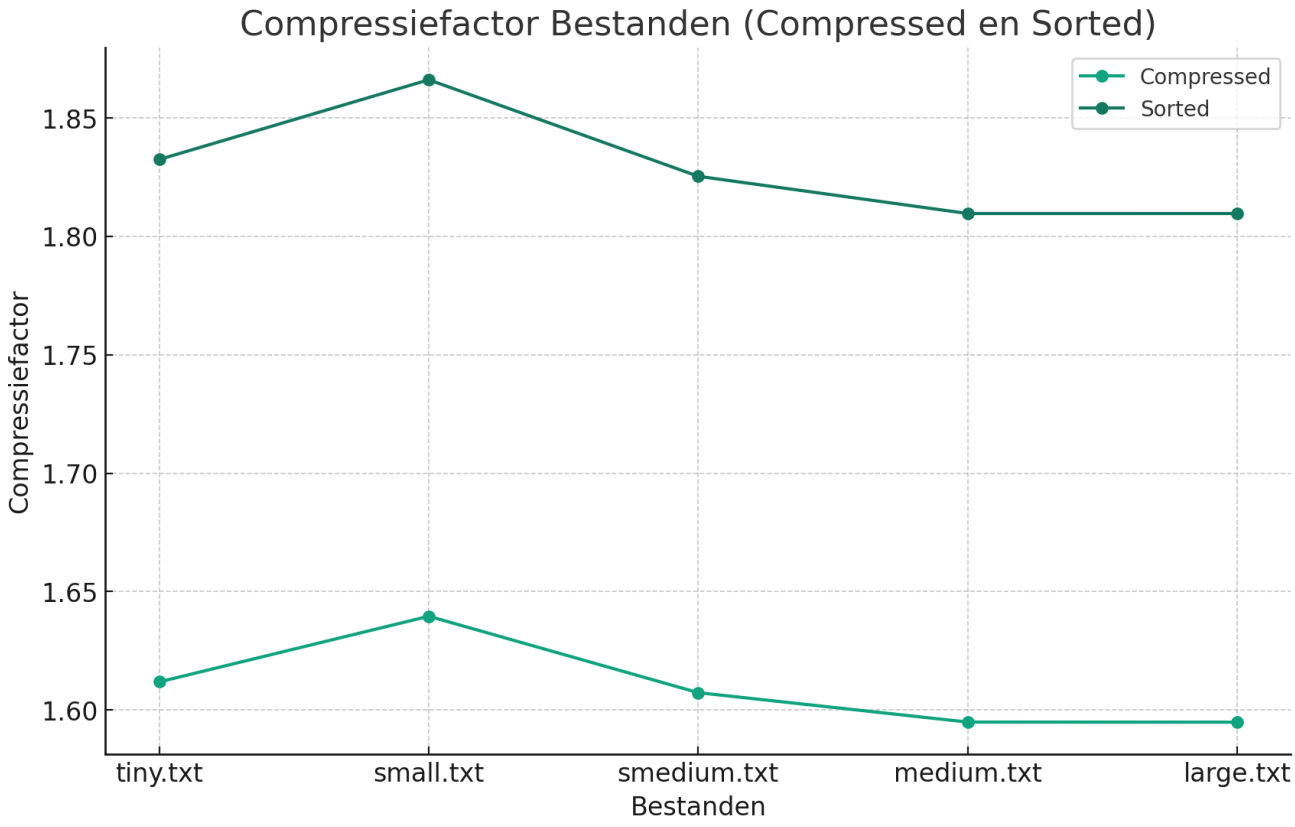

We zien dat de compressiefactor na het comprimeren ongeveer `1.60` bedraagt en na het sorteren ongeveer `1.82`. Aangezien de lijnlengtes hier verdwenen zijn zal veel beter dan dit niet gaan (met orde-bewarende prefix codes).

Extraheren## Inhoudsopgave

Bij het extraheren wordt de boom in de header verwerkt. Daarna worden de codes bit per bit ingelezen. Elke bit stemt overeen met een afdaling in de boom. Wanneer men een blad tegenkomt weten we het karakter dat uitgeschreven zal moeten worden.

Sorteren

Doordat lijnlengtes sequentieel worden bijgehouden in de header kunnen we deze snel overlopen en berekenen hoeveel lijnen er in elk blok passen. Op basis van deze lijnlengtes construeren we voor elke lijn een `struct` met de lengte van de lijn en waar deze begint (in de ingeladen buffer). Deze `struct`'s worden nadien gesorteerd via Heap-sort en uitgeschreven naar een tijdelijk bestand. De keuze voor Heap-sort was hoofdzakelijk omdat dit een "in-place" sorteer algoritme is dat dus - buiten de lijst waarin gesorteerd wordt - geen extra geheugen gebruikt.

Wijzers naar het begin van de blokken in dat bestand wordt ook bijgehouden. Daarna worden `m` (aantal blokken) inputbuffers[5] aangemaakt en één outputbuffer[5-1]. Nu zal volgens het extern sorteren algoritme telkens uit de eerste lijnen van het blok de kleinste gekozen en uitgeschreven worden tot de blokken leeg zijn.

Een performantie-analyse en vergelijking met Unix sort is te vinden in de Benchmarks sectie

Benchmarks

Elk van de commando's (`tree`, `compress`, `extract`, `sort`) zal toegepast worden op elk test-bestand (`tiny.txt`, `small.txt`, `smedium.txt`, `medium.txt` en `large.txt`) met een vaste geheugengrootte `m = 1GiB`. We verkrijgen de volgende tabel en grafieken:

Command	Tree_Mean	Compress_Mean	Extract_Mean	Sort_Mean
tiny	0.45 ms	0.52 ms	0.80 ms	0.80 ms
small	1.65 ms	9.94 ms	45.37 ms	69.63 ms
smedium	55.15 ms	476.00 ms	2.48 s	9.98 s
medium	106.43 ms	949.21 ms	5.20 s	22.99 s
large	500.09 ms	5.04 s	26.30 s	127.64 s

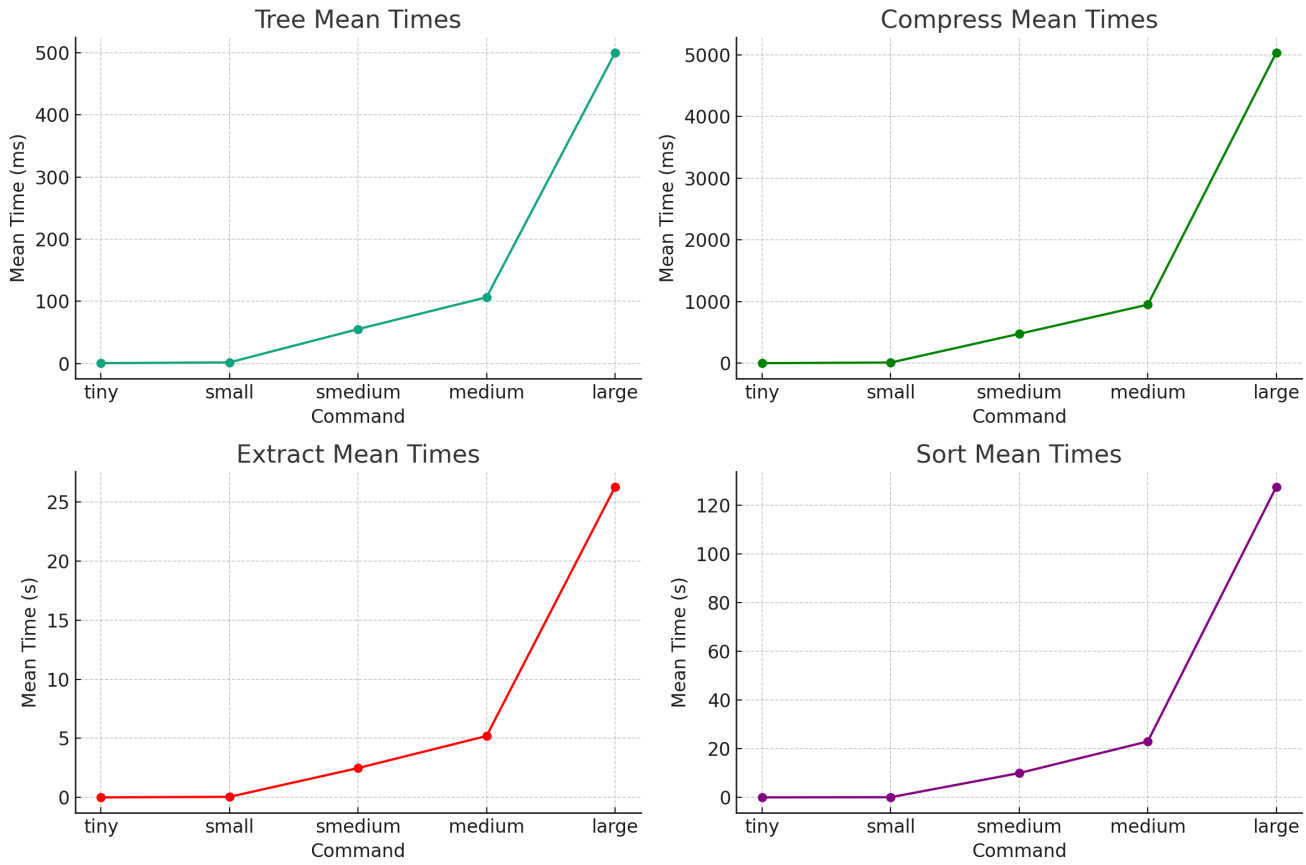

Daarna passen we elk commando toe op `large.txt` met variërende `m`. Om de invloed hiervan te bekijken laten we `m` lopen van `2% = 19MiB` naar `100% = 945MiB` van de bestandsgrootte in stappen van `7%` (`2`, `9`, `16`, `23`, `30`, `37`, `44`, `51`, `58`, `65`, `72`, `79`, `86`, `93`, `100`).

Tree

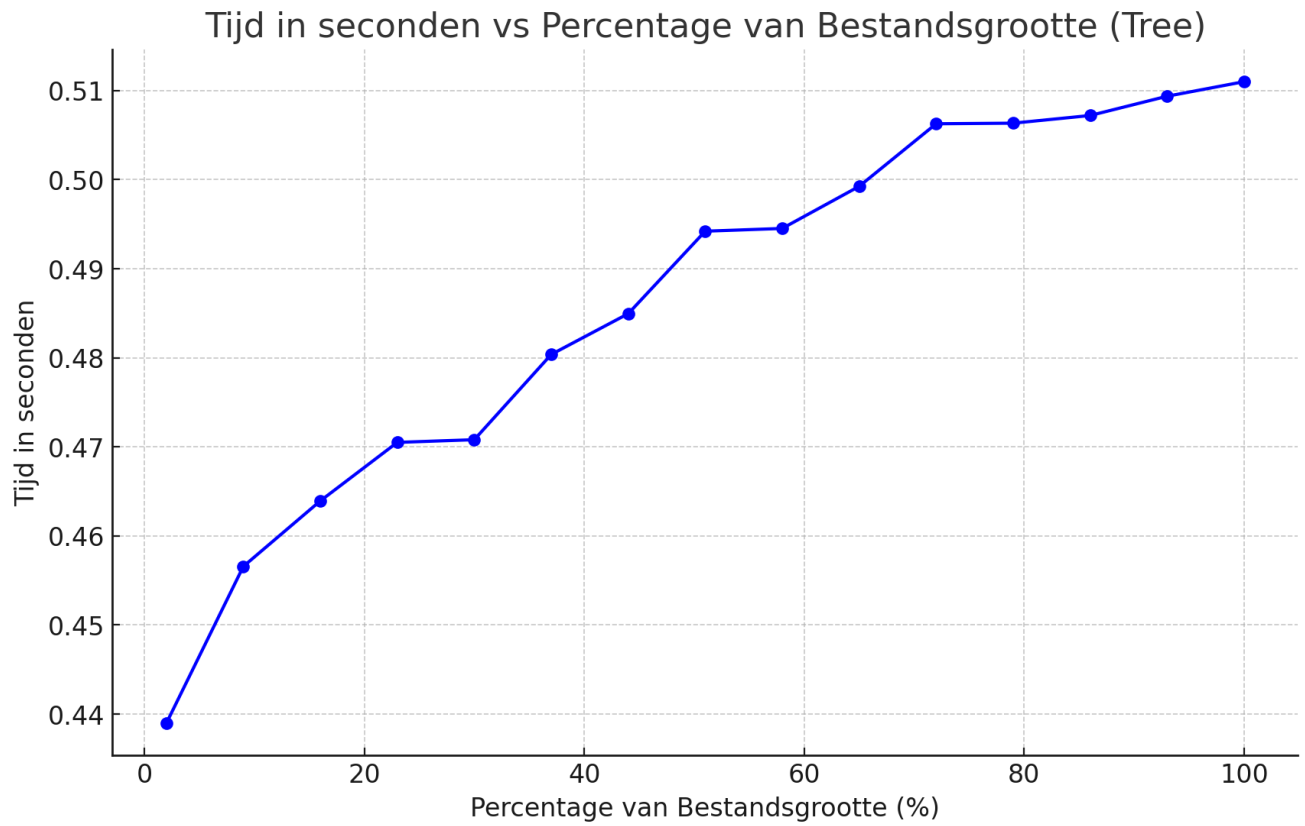

We zien dat het programma sneller is wanneer minder geheugen wordt meegegeven. Dit is contra-intuïtief en heeft misschien te maken met het feit dat kleine buffergroottes er voor zorgen dat data minder snel verdrongen wordt uit de systeem-cache. Hierdoor kan het systeem vaker cache data gebruiken en zal het programma sneller uitvoeren.

Compress

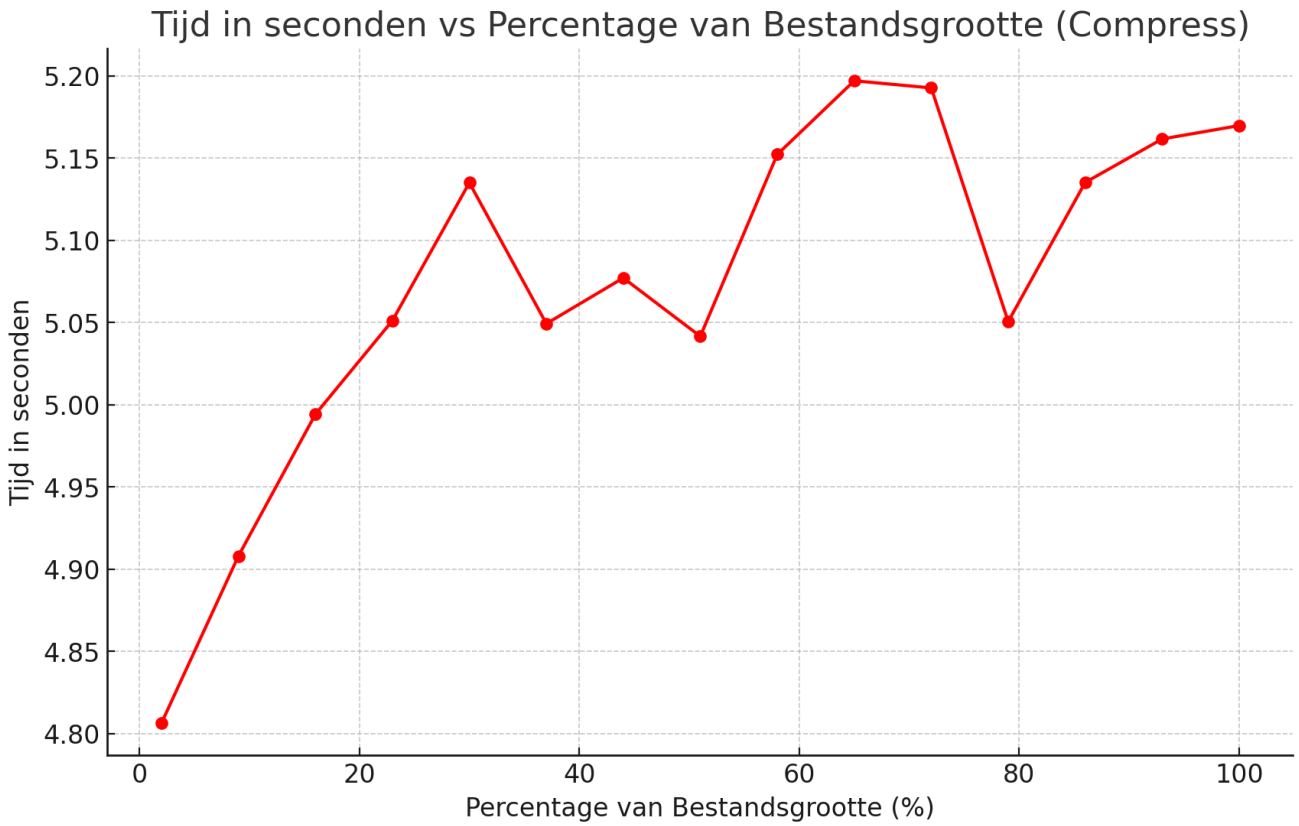

We zien hetzelfde fenomeen bij de `compress` functie.

Extract

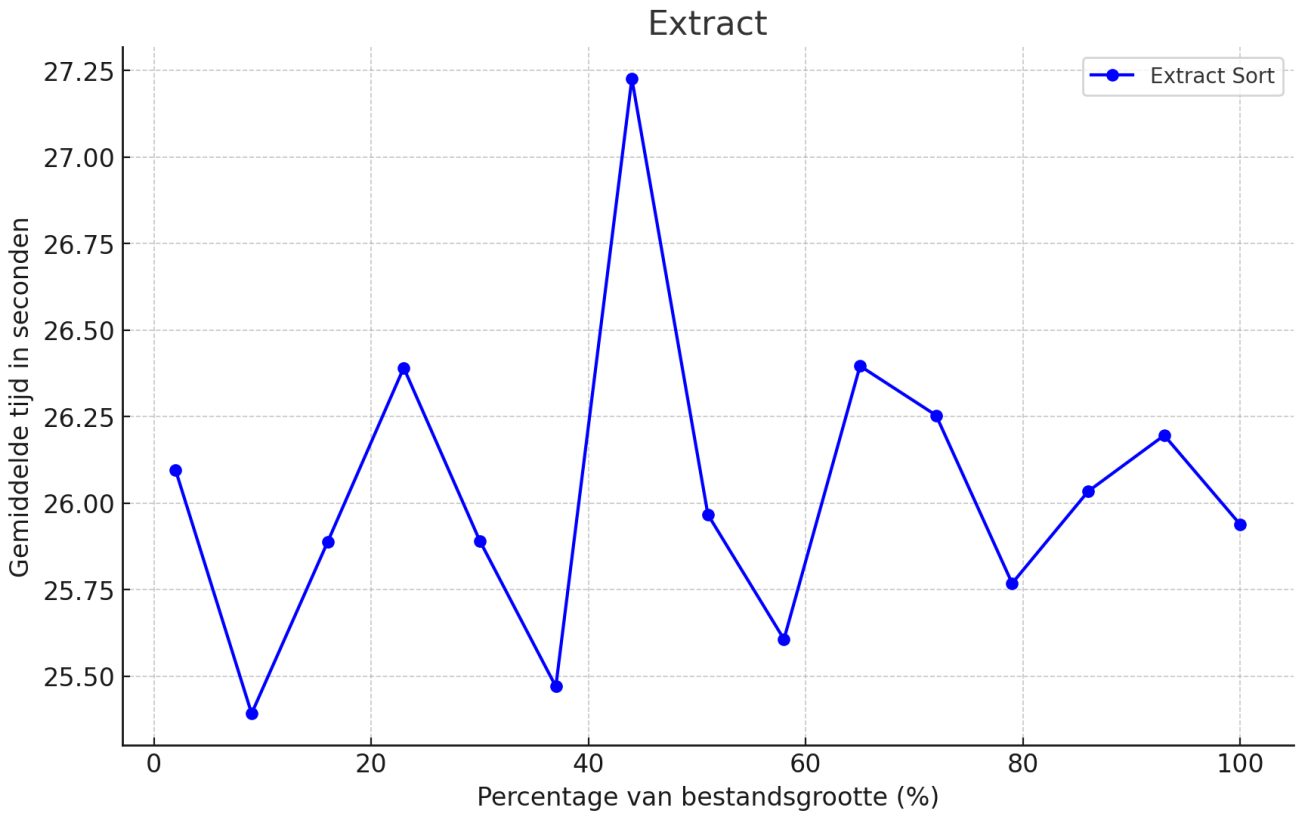

Extract lijkt niet al te veel beïnvloed te worden door de parameter `m`

Sort: OPC VS Bash

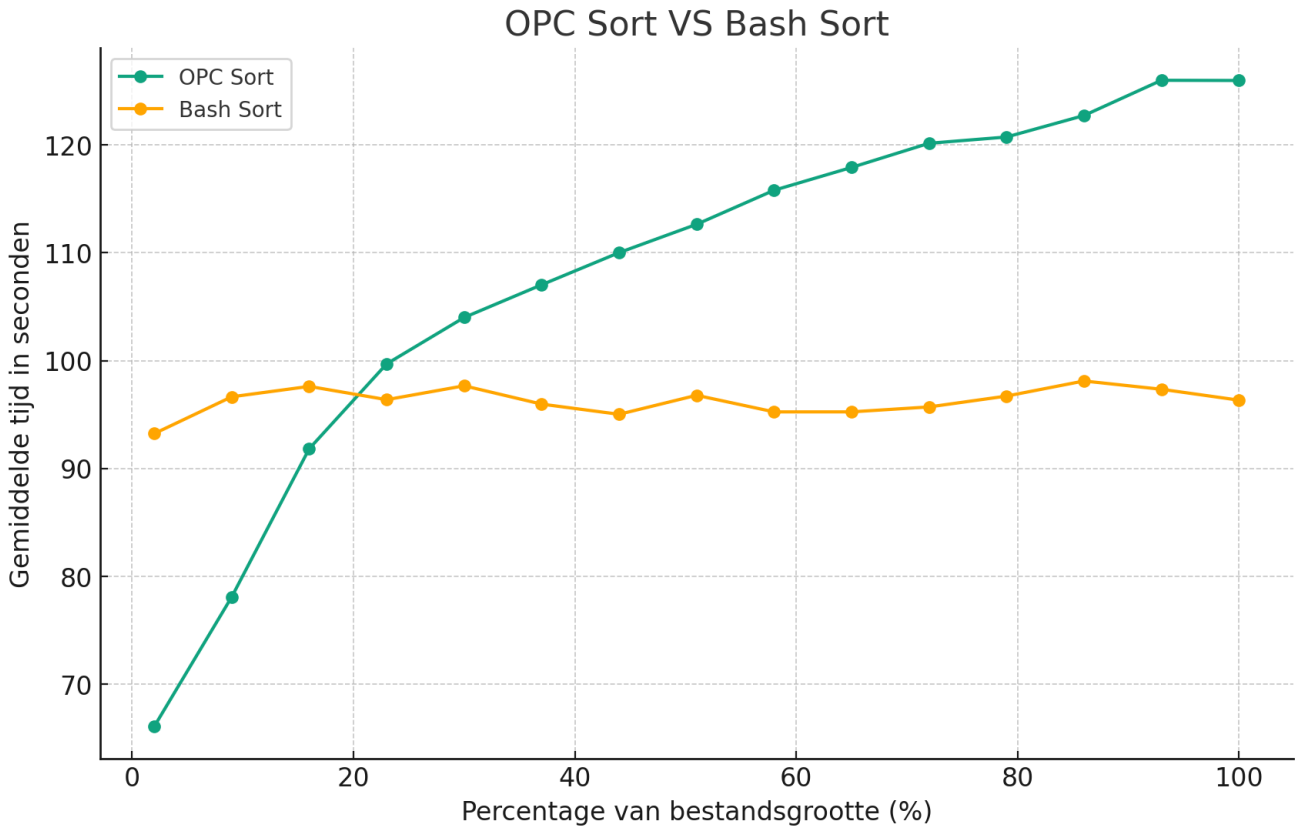

Het is te zien dat Bash sort[6] insensitief is aan veranderingen in buffergrootte. De executietijd van OPC sort stijgt daarintegen eenduidig mee met de parameter `m`. Dit zou opnieuw kunnen zijn omdat de cache efficiënter gebruikt wordt bij kleine buffergroottes. Het

lijkt erop dat het OPC programma dus de voorkeur geniet, aangezien gewoon altijd een kleine `m` genomen kan worden. Hierdoor zal het altijd sneller lopen dan bash sort.

Opmerkingen

Opmerking 1

Doorheen het project zijn een aantal belangrijke structuren gedefinieerd. De twee belangrijkste zijn `BitInputHandler` en `BitOutputHandler`. Deze twee `struct`'s implementeren het uitschrijven en inlezen van een arbitrair aantal bits. Omdat ik niet met uint64 of byte alignment werk was deze abstractie nodig om dit project proper en haalbaar te houden. Bij het creëren van deze structuren moet het aantal bytes meegegeven worden die de buffer achterliggend zal gebruiken. Dit is handig bij bijvoorbeeld het mergen van blokken wanneer er `k` `BitInputHanlders` aangemaakt kunnen worden met elk `m / k` bytes als buffergrootte.

Opmerking 2

In het begin van dit project schreef ik uit per byte. Dit heb ik later veranderd naar uitschrijven per `uint64_t` om performantie redenen. Door tijdsnood heb ik niet meer alle variabelenamen kunnen veranderen van byte naar uint64. zo moet `significantBitsInLastByte` bijvoorbeeld `significantBitsInLastUint64` zijn

Conclusie

De keuzes die ik in het project heb gemaakt zijn eerder gericht om de compressiefactor zo goed mogelijk te maken, bijvoorbeeld het ongealigneerd laten van de codes, het logaritme nemen van de lijnlengte en het weglaten van deze lengtes na het sorteren.

Ik heb ingezet om code proper en leesbaar te maken zonder hiervoor de performantie te laten inboeten. Ik hoop dat dit gelukt is.

Lukas Barragan Torres

---

1. Hu, T. C., & Tucker, A. C. (1971). Optimal Computer Search Trees and Variable-Length Alphabetical Codes. *SIAM Journal on Applied Mathematics*, *21*(4), 514–532. http://www.jstor.org/stable/2099603↩
2. Dit heb ik zelf gevonden na het lezen van https://math.mit.edu/~djk/18.310/18.310F04/huffman_algorithms.html↩
3. Knuth, D. E. (1997). *The art of computer programming* (3rd ed.). Addison Wesley.↩
4. Men zou natuurlijk wel het argument kunnen maken dat dit gesorteerd bestand nog doorzocht zou moeten worden. In dat geval zou het misschien beter zijn dit niet weg te laten.↩
5. Deze structuren wordt in meer detail uitgelegd in de Opmerkingen sectie↩↩

6. het commando waarmee Bash sort werd opgeroepen is `sort ../data/large.txt -o ../data/large_sorted.txt -S {m} --parallel=1`↩